


Presentación de resultados: prueba Científico de datos SemiSenior

Candidato



Alejandro Montenegro Taborda



Propósitos

Objetivos y alcances de la presentación



Propósitos

- Presentar la propuesta de algoritmo clasificadorio para la prueba de Científico de datos.
 - Mostrar la etapa de diseño desde una perspectiva de Desarrollador.
 - Evidenciar las etapas del proceso de diseño e implementación de algoritmos.
- Provocar en el público reacciones, comentarios y/o sugerencias que puedan aportar a la construcción y ejecución del trabajo realizado.



Contextualización

Información sobre el problema planteado



Caso Compañía A

- **Problema:** Ventas efectivas bajas (tarjetas de crédito)
- **Interés:** Incrementar y optimizar el número de ventas efectivas
- **Propuesta:** Creación de un modelo de predicción de clientes con mayores probabilidades de aceptar una tarjeta de crédito

Estado actual e impresión de resultados.



Conjunto de datos (cat.)


- Tipo_Trabajo (categórica): Trabajo ejercido por el cliente.
- Estado_Civil (categórica): Estado civil del cliente.
- Educacion (categórica): Nivel educativo alcanzado por el cliente. datos desconocidos
- mora (categórica): Informa si el cliente se encuentra en mora.
- Vivienda (categórica): Informa si el cliente cuenta con vivienda propia.
- Consumo (categórica): Informa si el cliente presenta consumo.
- Contacto (categórica): Tipo de medio por el cual el cliente es contactado.
- Mes (categórica): Mes del contacto.
- Dia (categórica): Día del contacto.
- Campana (categórica): Número de identificación de la campaña.
- Resultado_Anterior (categórica): Resultado obtenido en la campaña previa.
- nr_employed (categórica): Identificación del agente por el cual fue contactado el cliente.
- y (categórica): Variable objetivo que indica si el cliente ha aceptado una tarjeta de crédito.



Conjunto de datos (núm.)

- ID (numérica): Identificación del cliente.
- Edad (numérica): Edad del cliente.
- Dias_Ultima_Camp (numérica): Días transcurridos desde el último contacto en otra campaña. outliers
- No_Contactos (numérica): Número de veces que se ha contactado al cliente.
- emp_var_rate (numérica): (Tasa de variación del empleo): Este indicador mide la estabilidad del empleo del cliente.
- cons_price_idx (numérica): el índice de precios al consumidor es un indicador que mide el nivel de vida del cliente.
- cons_conf_idx (numérica): El índice de confianza del consumidor es un indicador que mide el grado de optimismo que los consumidores sienten sobre el estado general de la economía.
- euribor3m (numérica): La tasa Euribor a 3 meses es un indicador de la tasa de interés a la que los bancos se prestan dinero entre sí a corto plazo.

Pero antes...



*La arquitectura es agnóstica a la
tecnología*

“





Etapa de diseño


Diseño de la arquitectura



Aspectos tenidos en cuenta

- **POO y Entornos virtuales:** Diseño pensado en algunas oportunidades de mejora observadas.
- **Infraestructura en la nube:** Optimización pensada en infraestructura de la nube (cobro por procesos).
- **PEP8 y seguridad:** Implementación usando buenas prácticas (internacionales).

*Ahora sí
¡Empecemos!*





Procesos llevados a cabo

Etapa 1

Etapa 2


Etapa 3

Etapa 4

Etapa 5




Descripción general





Descripción general





Descripción general

Etapa 1

Etapa 2

**Preproce-
samiento**

Etapa 4

Etapa 5



Descripción general

Etapa 1

Etapa 2

Etapa 3

Modelo

Etapa 5



Descripción general

Etapa 1

Etapa 2

Etapa 3

Etapa 4

**Desplie-
gue**



Limpieza de datos

Homogeinización de datos y capas de seguridad



Limpieza de datos


- Datos desconocidos
- Columnas irrelevantes
- Filas duplicadas
- Valores ilógicos
- Uso de minúsculas
- Códificación de datos
- Protección de datos sensibles
 - Id del cliente
- Ciberseguridad UUID
 - Encriptación de identidad
 - Desencriptación del usuario




EDA

Analisis exploratorio de datos

Tipos de datos



	ID	Edad	Dias_Ultima_Camp	No_Contactos	emp_var_rate	cons_price_idx	cons_conf_idx	euribor3m	y
count	23099.000000	23099.000000	23099.000000	23099.000000	23099.000000	23099.000000	23099.000000	23099.000000	23099.000000
mean	16420.136499	40.067665	962.976060	0.171003	0.095649	85576.471847	-40.485237	3190.939789	0.112126
std	9521.074915	10.449983	185.675409	0.494079	1.565650	26224.436234	4.629643	2088.703058	0.315528
min	1.000000	18.000000	0.000000	0.000000	-3.400000	93.200000	-50.800000	0.634000	0.000000
25%	8158.000000	32.000000	999.000000	0.000000	-1.800000	92893.000000	-42.700000	1281.000000	0.000000
50%	16375.000000	38.000000	999.000000	0.000000	1.100000	93876.000000	-41.800000	4856.000000	0.000000
75%	24644.500000	47.000000	999.000000	0.000000	1.400000	93994.000000	-36.400000	4961.000000	0.000000
max	32967.000000	95.000000	999.000000	6.000000	1.400000	94767.000000	-26.900000	5045.000000	1.000000







Dataviz


Visualización de datos en el EDA



● Análisis univariado



Una vez se han identificado las oportunidades de mejora, así como las fortalezas de la compañía, se realizarán transformaciones a los datos en pos de explotar dichas características.





Preprocesamiento

Transformación de datos guiada por el EDA



Innovación y explotación

● Imputación de datos

- Imp. Simple: uso de la moda por ser variables categóricas
- Imp. Hot-Deck (IA): uso de imputación por algoritmo KNN.

● Codificación de variables categóricas



Modelo

Creación del modelo



AutoML y Modelo

Hiperparametrización

Preparación para hiperparametrización de 19 posibles modelos.

Comparación

Comparación de resultados de clasificación (16 modelos).

Selección del modelo

Selección del modelo *Ada Boost Classifier* a juicio humano.

Entrenamiento iterativo

Entrenamiento iterativo (10) usando los datos de entrenamiento.

Resultados

Resultados finales del modelo: Precisión del 91 % en la clasificación de adquisición efectiva.

Distribución del modelo

Guardado del modelo para su posterior distribución a los demás miembros del equipo en caso de necesitarse.



Despliegue

Distribución del modelo



Ambiente productivo

1. Lectura de datos y modelo.
2. Preprocesamiento de datos (datos a predecir).
3. Predicción en datos finales.
4. Simulación de exportación de datos a base de datos SQL.



Comentarios


Comentarios finales sobre el proceso




¿El modelo puede mejorar?

Seguramente **sí**.

¿Cómo?


Implementar arquitecturas diferentes o enriquecimiento de datos.





89.7 %

De precisión en la clasificación de adquisición de tarjetas de crédito.





¡Gracias!

Alejandro Montenegro Taborda

Candidato

amontenegrot@outlook.com